Propuesta Inicial – Proyecto BD II

Integrantes:

Medina Grados Fabian Esteban
Vargas Llerena Bryan Aron
Villanueva Valencia Andy Jeferson
Chavez Quijahuaman Jorge
Becerra Reymer Leonardo Sebastian

1. Estructura elegida y motivación

El grupo eligió implementar ISAM (Indexed Sequential Access Method) como estructura alternativa de indexación. La motivación combina dos factores: (a) ISAM organiza los registros de forma secuencial ordenada con un índice jerárquico por niveles apuntando a bloques de datos, lo cual permite soportar de forma natural tanto búsquedas por igualdad como por rango, ambas exigidas por la rúbrica; y (b) la estructura es clásica y bien documentada en la literatura, lo que facilita un diseño robusto desde sus fundamentos. El equipo desarrollará los componentes esenciales de la estructura ISAM: organización de datos, índice de niveles, manejo de overflow y su integración funcional con PostgreSQL sin depender de implementaciones previas, asegurando así un control total sobre la arquitectura y el desempeño.

2. Referencias fundamentales

- Ramakrishnan, R. & Gehrke, J. (2003). Database Management Systems (3ra ed.), capítulo 8 ("Storing Data: Disks and Files") y capítulo 10 ("Tree-Structured Indexing"). Fuente académica de referencia para la organización de ISAM como índice estático de dos niveles sobre un archivo secuencial.
- Silberschatz, A., Korth, H. & Sudarshan, S. Database System Concepts, capítulo sobre estructuras de indexación estática, que describe el algoritmo clásico de manejo de páginas de overflow enlazadas.
- Documentación oficial de PostgreSQL, capítulo "Index Access Method Interface" (https://www.postgresql.org/docs/current/indexam.html), fuente técnica primaria para el diseño de la estrategia de integración (sección 5).

3. Representación de la estructura y operaciones a implementar

ISAM se representará con dos capas:

- **Índice (estático, construido una vez):** árbol de niveles fijos donde cada entrada de un nivel apunta al primer valor de clave de un bloque del nivel inferior; el nivel más bajo apunta directamente a los bloques de datos.
- **Área de datos (secuencial y ordenada):** bloques de tamaño fijo con registros ordenados por clave, más un área de overflow simplificada (lista enlazada por bloque) para inserciones que no caben en su bloque original.

Operaciones mínimas a implementar, según lo exigido en la sección 4 de la rúbrica:

- Construcción: carga de un dataset ordenado, cálculo de bloques y armado del índice de niveles.
- Búsqueda: descenso por el índice hasta el bloque candidato, búsqueda dentro del bloque (y su cadena de overflow si aplica).
- Inserción con overflow simplificado: ubicación del bloque correspondiente y, si está lleno, encadenamiento a un bloque de overflow asociado.

La construcción del índice será aproximadamente O(N), mientras que la búsqueda tendrá un costo aproximado de O(log N + B), donde B representa el costo de recorrer el bloque y, cuando corresponda, su cadena de overflow. La inserción tendrá un comportamiento similar, pudiendo aumentar su costo cuando sea necesario utilizar bloques de overflow.

4. Tipo de clave y consultas soportadas

Se soportará clave de tipo INTEGER (datasets D1/D2/D3) como caso principal para las comparaciones obligatorias con B-tree, dado que ISAM está listado en la rúbrica con consulta principal de "igualdad y rango". Las consultas soportadas son: búsqueda exacta (W1/W2) y búsqueda por rango (W4). No se trabajará con VARCHAR/prefijos (D4/D5), ya que esos datasets están orientados a estructuras de tipo Radix Tree.

5. Estrategia de integración con PostgreSQL

Se optará por un Index Access Method (AM) propio registrado vía CREATE ACCESS METHOD ... TYPE INDEX, siguiendo la interfaz IndexAmRoutine de PostgreSQL 18.6. Esto permite ejecutar CREATE INDEX ... USING isam_am sobre una tabla real y que el planner invoque nuestras funciones al resolver consultas de igualdad y rango, cumpliendo el requisito de que "no será suficiente tener un programa externo que lea un CSV o que solamente envíe consultas a PostgreSQL".

Se implementarán, en C, los callbacks mínimos necesarios:

- ambuild / ambuildempty — construcción del índice a partir de los datos existentes en la tabla.
- aminsert — inserción de una nueva tupla en la estructura ISAM.
- ambeginscan / amrescan / amgettuple / amendscan — recorrido para igualdad y rango.

- amcostestimate y demás callbacks obligatorios de la interfaz se implementarán con versiones mínimas/estimaciones simplificadas, ya que la rúbrica no exige estimación sofisticada de costos.

Quedan fuera de alcance : concurrencia completa, WAL propio, VACUUM especializado y soporte completo de unicidad.

6. Componentes a desarrollar por el equipo

- Se construye una implementación del área de datos secuencial para ISAM, con su propio módulo de organización de bloques y cálculo del layout físico de los registros, junto con la lógica de indexación, manejo de overflow y acceso a los datos. Toda la lógica de indexación, manejo de overflow y acceso a datos se diseña específicamente para los requerimientos de este proyecto.
- Los componentes desarrollados íntegramente para esta solución incluyen: la construcción del índice de niveles de ISAM, el manejo de overflow simplificado, los callbacks del Access Method en C, los generadores de datasets D1/D2/D3, y los scripts de workload (W1, W2, W3, W4) junto con los scripts de benchmarking que permiten comparar el rendimiento contra acceso sin índice y contra B-tree.

7. Recursos externos, repositorios o bibliotecas

- Documentación oficial de PostgreSQL (Index Access Method Interface, Server Programming Interface) como referencia técnica de la API en C.
- Ejemplos de access methods incluidos en el código fuente de PostgreSQL (contrib/bloom y access/heap) como referencia de convenciones de código y patrones de diseño, no como código a copiar directamente.
- Librerías estándar de C (libc) para manejo de archivos y memoria; no se prevé uso de bibliotecas externas de terceros para la estructura en sí.

8. Riesgos técnicos identificados y plan de trabajo

Riesgo	Impacto	Mitigación
Adaptar la API de Access Methods de PostgreSQL 18.6 (curva de aprendizaje en C interno)	Puede retrasar la Semana 4 (integración)	Dedicar la Semana 1 a un prototipo mínimo ("hello world" AM) antes de portar la lógica de ISAM
Manejo de overflow simplificado puede generar degradación de rendimiento en accesos sesgados (dataset D3)	Resultados poco representativos en la Etapa II	Definir un umbral de reorganización simple y documentarlo como limitación conocida en el informe final
Desarrollo completo desde cero de todas las capas (disco, layout, índice, overflow, AM) implica mayor esfuerzo de codificación	Mayor carga de trabajo en las primeras semanas	Priorizar el desarrollo del módulo de disco y layout en la Semana 1, paralelamente al prototipo del AM, para no comprometer el cronograma
Reparto desigual de comprensión entre integrantes (riesgo para la defensa individual)	Bajo desempeño individual en la evaluación	Sesiones internas de code review cruzado antes de cada entrega del cronograma, asegurando que todos los integrantes participen activamente en todas las capas del proyecto

Plan de trabajo (Etapa I, 5 semanas):

S1 :diseño y prototipo de AM

S2 :construcción y búsqueda funcionando

S3 :inserción con overflow y demo de código

S4 :integración completa con PostgreSQL

S5 :demo reproducible y comparación preliminar con B-tree para el parcial.